

Machine Learning – podejście praktyczne

Warsztaty I

Podziękowania



Rządowy Program
Fundusz Młodzieżowy
na lata 2022-2033
**Fundusz
Młodzieżowy**



SFINANSOWANO ZE ŚRODKÓW NARODOWEGO INSTYTUTU WOLNOŚCI – CENTRUM ROZWOJU SPOŁECZEŃSTWA OBYWATELSKIEGO
W RAMACH RZĄDOWEGO PROGRAMU FUNDUSZ MŁODZIEŻOWY NA LATA 2022-2033

Cel warsztatów

- Standardowe kursy uczenia maszynowego są spoko...
 - architektury modeli uczenia maszynowego
 - rozważania teoretyczne
 - zadania praktyczne na wybranych zbiorach danych
- ...brakuje w nich jednak elementów przydatnych w pracy lub badaniach
 - fine-tuning
 - rozwiązywanie problemu ograniczonego VRAM-u
 - praca na serwerach GPU
 - triki przyspieszające obliczenia

Plan warsztatów

- I spotkanie (dzisiaj)
 - sieci neuronowe w kilka minut
 - biblioteka PyTorch
 - `torch.compile`
 - `torch mat_mul precision`
- II spotkanie (jutro)
 - Przegląd dostępnych modeli “State of the Art”
 - Praca z literaturą naukową
 - HuggingFace

Plan warsztatów

- 2 spotkania w przyszłym tygodniu:
 - Trening i inferencja z wykorzystaniem pretrenowanych modeli
 - Praca na zewnętrznych serwerach
 - Fine-tuning i inferencja modeli dostępnych poprzez API
- Mini-projekty
 - proponujemy kilka prostych projektów do realizacji
 - zapewniamy wsparcie, moc obliczeniowa, dostęp do API LLMów
 - zachęcamy do krótkiej prezentacji wyników na dedykowanym spotkaniu
 - pizza

nkr.si/warsztaty – aktualizowana na bieżąco

Warsztaty

Zapisy trwają! **Wypełnij formularz zgłoszeniowy**

Jak wziąć udział w warsztatach zdalnie?

1. Wypełnij powyższy formularz zapisów.
2. Prześlij podpisany (elektronicznie lub tradycyjnie) formularz RODO na adresy: wydarzenia@inuni.org.pl i nkrsi@uj.edu.pl (jedna wiadomość z dwoma adresami), o tytule: "[Zapisy warsztaty ML][IMIĘ NAZWISKO NICK_DISCORD]". Formularz dostępny jest **tutaj**.
3. Dołącz do **serwera Discord na którym będą transmitowane warsztaty**. Ustaw nick serwerowy na imię i nazwisko.

Jak wziąć udział w warsztatach na miejscu?

1. Wypełnij powyższy formularz zapisów.
2. Przyjdź na spotkanie. (informacje jak dotrzeć – poniżej)


Harmonogram


Cztery spotkania warsztatowe:


Problem predykcji


bedrooms	size	location	age	price
4	2680	2	8	1.75M
5	700	1	27	750K
3	2360	1	28	1.2M
5	1280	2	98	1.05M
5	3480	3	21	2.3M


Sieci neuronowe




















$$w_1 \cdot \text{bedrooms} + w_2 \cdot \text{size} + w_3 \cdot \text{location} + w_4 \cdot \text{age}$$



$$w_1 \cdot \text{bedrooms} + w_2 \cdot \text{size} + w_3 \cdot \text{location} + w_4 \cdot \text{age}$$

$$w_1 \cdot \text{bedrooms} + w_2 \cdot \text{size} + w_3 \cdot \text{location} + w_4 \cdot \text{age} + \underset{\text{bias}}{\overset{c}{b}}$$

magic, part 1

$$\begin{aligned} w_1 \cdot \text{bedrooms} + w_2 \cdot \text{size} + w_3 \cdot \text{location} + w_4 \cdot \text{age} + b \\ = \sum_{i=1}^n w_i x_i + b \end{aligned}$$

Funkcja aktywacji


magic, part 2

$$f\left(\underbrace{\sum_{i=0}^n w_i x_i + b}_{\text{input}}\right) = \text{output}$$

Czy funkcja liniowa jest rozsądną funkcją aktywacji?

linear activation


$$f(x) = x$$



Sigmoid




$$f(x) = \frac{1}{1 + e^{-x}}$$





ReLU


rectified linear units

$$f(x) = \max(x, 0)$$










$$f(x) = \max(x, 0)$$


$$\Rightarrow f(1,036,000) = 1,036,000$$


$$\sum_{i=0} w_i x_i + b$$


$$\begin{aligned} &= 50,000 \cdot 4 + 300 \cdot 2680 + 2 \cdot 20,000 + 8 \cdot -1000 + 100,000 \\ &= 1,036,000 \end{aligned}$$


bedrooms	size	location	age	price	predicted price
4	2680	2	8	1.75M	1,036,000
5	700	1	21	750K	453,000
3	2360	1	28	1.2M	870,000
5	1280	2	98	1.05M	576,000
5	3480	3	21	2.3M	1,333,000



















layer 0
(input layer)


layer 1
(hidden layer)

layer 2
(output layer)






bedrooms	size	location	age	price
4	2680	2	8	1.75M




$$\textcircled{2} \Sigma: 10000(4) + 500(2680) - 1000(2) + 5000 = 1,383,000$$

$$\text{✓}: \max(1,383,000, 0) = 1,383,000$$




$$\textcircled{3} \quad \Sigma: 30000(2) + 200(8) \\ + 8000 = 69,600$$

$$\checkmark: \max(69600, 0) \\ = 69600$$



$$(4) \Sigma: 1.5(507000) + 0.8(1383000) + 2.2(696000) + 30000 = 2,050,020$$

$$\checkmark: \max(2050020, 0) = 2,050,020$$




bedrooms	size	location	age	price	predicted price
4	2680	2	8	1.75M	2,050,020
5	700	1	27	750K	793,680
3	2360	1	28	1.2M	1,820,820
5	1280	2	98	1.05M	1,252,620
5	3480	3	21	2.3M	2,658,940

actual
value

predicted
value

$$MSE = \frac{1}{n} \sum (y - \hat{y})^2$$



Notebook

<https://colab.research.google.com/drive/1A5QiFxXWcde60p6ahggQV3x7m1RTFoNN?usp=sharing>

Matmul Precision

```
14 + import torch
```

```
15 + torch.set_float32_matmul_precision('medium')
```

Wewnętrzna precyzja mnożenia macierzy float32


Cel: Zwiększenie wydajności przy znikomej utracie dokładności obliczeń.

Poziomy precyzji:

„highest” – pełny float32 (23 bity mantysy)

„high” – TF32 (10 bitów) lub 2× bfloat16 (~14 bitów)

„medium” – bfloat16 (7 bitów)



torch.compile

JIT kompilacja

```
def foo(x, y):  
    a = torch.sin(x)  
    b = torch.cos(y)  
    return a + b  
  
opt_foo1 = torch.compile(foo)  
print(opt_foo1(torch.randn(3, 3), torch.randn(3, 3)))  
  
@torch.compile  
def opt_foo2(x, y):  
    a = torch.sin(x)  
    b = torch.cos(y)  
    return a + b  
  
print(opt_foo2(torch.randn(3, 3), torch.randn(3, 3)))
```

908

+

model.compile()

Torch.compile, matmul_precision

Runtime per configuration and model

Description	finer	relu	siren	wire	avg_all	avg_no_wire
Before reducing number of files.	1147	994	1092	1716	1237	1078
current main, torch 2.2, I/III	936	796	881	1526	1035	871
current main, torch 2.2, II/III	954	799	899	1501	1038	884
current main, torch 2.2, III/III	946	802	905	1506	1040	884
compilation enabled, torch 2.2	872	790	865			842
compilation enabled, torch 2.2, medium precision	782	669	773			741
compilation enabled, torch 2.7	727	668	731	1403	882	709
compilation enabled, torch 2.7, medium precision	548	504	556	931	635	536

Źródła

<https://towardsdatascience.com/neural-networks-illustrated-part-1-how-does-a-neural-network-work-c3f92ce3b462/>

<https://docs.pytorch.org/docs/2.11/index.html>

<https://deeprec.readthedocs.io/en/latest/NVIDIA-TF32.html>